Динамика связывания Foxd3 в ходе развития нервного гребня Danio rerio

Анализ ChIP-seq на стадиях 75% epiboly, 1–2 ss, 5–6 ss и 14 ss. Домашнее задание, семинар 2 (ChIP-seq).

Сервер: calc.cod.phystech.edu, пользователь studfbmf01_25. Все расчёты запускались через slurm (партиция AMD9554-common).

1. Цель работы

Повторить на стадиях 75% epiboly и 1–2 ss workflow, выполненный на семинаре для 14 ss (BAM QC → ChIP/Input BigWig → log2(ChIP/Input) → MACS3 peaks → p/q-value → FRiP → heatmap и average profile), сравнить четыре стадии 75ep → 1–2ss → 5–6ss → 14ss по числу peaks, FRiP, силе enrichment, перекрытию peaks и индексу Жаккара, показать три локуса в IGV и ответить, как меняется genomic binding landscape Foxd3 и какая часть различий биологическая, а какая может объясняться качеством ChIP-seq.

2. Использованные данные

- Данные взяты из статьи про bimodal-активность foxd3 в нервном гребне (GEO GSE106676): Foxd3 biotin-ChIP-seq и Input на четырёх стадиях. Референс: геном GRCz11, аннотация GRCz11.gtf; хромосомы названы по RefSeq (NC_0071xx.7), нехромосомные scaffolds называются NW_...
- Входные файлы: `foxd3_<stage>_{chip,input}.nuclear.bam` + .bai для 75ep, 1-2ss, 14ss (paired-end, митохондриальные alignments уже удалены).
- Для 5–6 ss использованы готовые результаты преподавателя (папка teacher/5-6ss: BigWig, narrowPeak, frip.tsv). BAM-файлов этой стадии нет, поэтому число Input alignments для неё неизвестно, а сама обработка могла идти с немного другими параметрами. Реплик в данных нет, воспроизводимость между репликами оценить нельзя.

3. Краткое описание файлов и форматов

Таблица описывает объект, который хранится в файле. Ниже таблицы разобрана цепочка BAM → BigWig → narrowPeak.

Формат	Что хранит	Text / Binary	Для чего использовали
FASTA (.fa)	Нуклеотидные последовательности хромосом и scaffolds референсного генома GRCz11 (.fai - индекс с длинами и смещениями).	Text	Референс для картирования и IGV; из него вырезан мини-геном трёх хромосом.
GTF	Аннотация генов: gene, transcript, exon, CDS, start/stop codon с координатами, цепью и атрибутами (gene_id, ...). Координаты 1-based, закрытые.	Text	Дорожка генов в IGV; определение генов рядом с peaks.
BAM	Выравнивания прочтений (пары mate) на геном: позиция, CIGAR, качество картирования, флаги.	Binary (BGZF)	Входные данные ChIP и Input; samtools flagstat/view; MACS3; bamCoverage.
BAI	Индекс BAM: позволяет читать регион без прохода по всему файлу.	Binary	Быстрый доступ к регионам (samtools view -L, IGV).
BigWig	Непрерывный количественный трек: значение сигнала (coverage, CPM или log2-отношение) в бинах вдоль генома.	Binary	ChIP CPM, Input CPM, log2(ChIP/Input) для IGV и computeMatrix.
BED	Список геномных интервалов (chrom, start, end, ...), координаты 0-based, полуоткрытые.	Text	summits.bed, списки общих и специфичных peaks, loci.bed, genes.bed.
narrowPeak	BED6+4: интервал peak, score, signalValue (fold-enrichment), -log10(p), -log10(q), положение summit.	Text	Главный результат MACS3, основа сравнения стадий и FRiP.

Формат	Что хранит	Text / Binary	Для чего использовали
MACS3 peaks.xls	Подробная таблица peaks MACS3 (сдвиги, pileup, fold enrichment, p/q) и заголовок с параметрами запуска. Несмотря на расширение, это текст.	Text	Проверка параметров запуска и деталей peaks.
TSV	Таблица со значениями, разделёнными табуляцией.	Text	summary.tsv по стадиям, pairwise.tsv, frip.tsv.
deepTools matrix.gz	Матрица «peaks × бины»: сигнал треков вокруг каждого summit (±2 kb, бин 20 bp) плюс заголовок с параметрами; сжата gzip.	Binary (gzip поверх текста)	Вход для plotHeatmap и plotProfile.
PDF	Готовые векторные графики и итоговый отчёт.	Binary	Heatmap и profile для каждой стадии; этот отчёт.

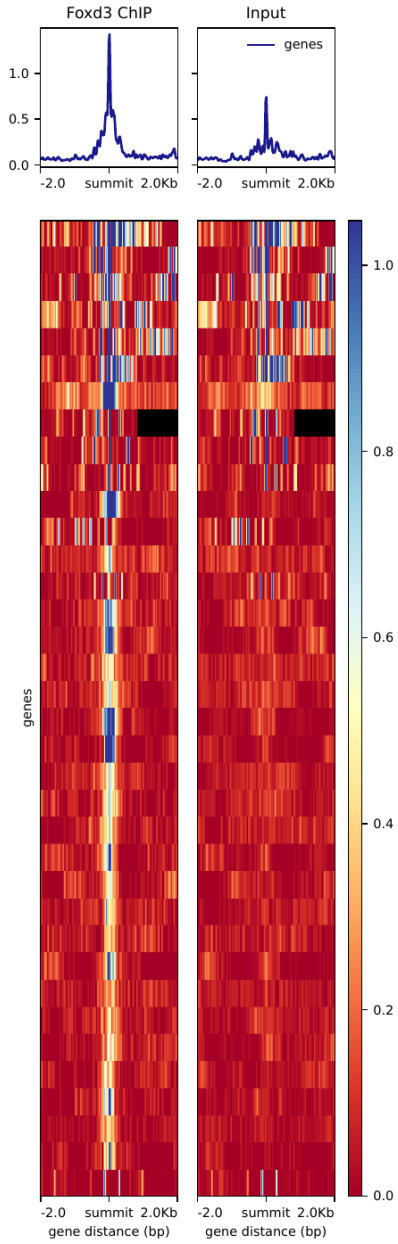
BAM → BigWig → narrowPeak. BAM хранит отдельные выравнивания (alignments): каждое прочтение с его позицией, парой и качеством. BigWig сворачивает их в непрерывный сигнал: для каждого бина считается покрытие, нормированное на глубину (CPM). Отдельные прочтения, пары и качество картирования при этом теряются. narrowPeak - дискретные enriched regions: MACS3 сравнивает ChIP с локальным фоном Input, считает p- и q-value и оставляет только интервалы выше порога. От сигнала остаётся один интервал со статистикой, а всё вне peaks исчезает. На каждом шаге данные сжимаются и интерпретируются: обратно от narrowPeak к сигналу или к alignments вернуться нельзя.

4. Методы

Окружение chipseq клонировано из общего (conda create --clone). Один и тот же скрипт запускался через sbatch для каждой стадии со всеми параметрами, как на семинаре:

- **QC:** samtools flagstat для ChIP и Input BAM; число alignments - samtools view -c.
- **Сигнал:** bamCoverage, нормировка CPM, бин 10 bp; log2(ChIP/Input) - bigwigCompare, pseudocount 1, бин 10 bp.
- **Peak calling:** macs3 callpeak, -f BAMPE, -g 1360000000, -q 0.01, ChIP против Input.
- **FRiP** = (число alignments в peaks, samtools view -c -L peaks.narrowPeak) / (все alignments ChIP BAM). Это доля alignments, а не фрагментов; для всех стадий считалось одинаково, для 5–6 ss взято из frip.tsv преподавателя.
- **Самый значимый peak:** сортировка narrowPeak по колонке 9 (-log10 q); q-value = $10^{-(\text{колонка 9})}$.
- **Профили:** computeMatrix reference-point по summits, ±2 kb, бин 20 bp; plotHeatmap и plotProfile.
- **Сравнение стадий:** peaks отсортированы; bedtools intersect -u (peaks A, пересекающиеся с B), -v (специфичные для A), bedtools jaccard (индекс Жаккара по нуклеотидам). Все шесть пар. Peaks 5–6 ss взяты из teacher/5-6ss.
- **IGV:** для файлов IGV окна ±50 kb вокруг выбранных peaks вырезаны из BigWig (pyBigWig), чтобы архив был небольшим. Шкалы треков в IGV автоматические.

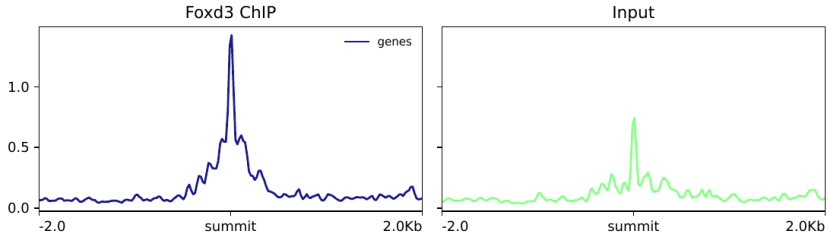
5. QC и peak calling для 75% epiboly



Heatmap ChIP и Input по summits (peaks отсортированы по ChIP-сигналу).

Показатель	Значение
ChIP / Input alignments	23 863 894 / 39 931 858
Peaks (q < 0.01)	36 (из них на scaffolds NW_: 2)
Reads in peaks / FRiP	4 101 / 0.00017
Самый значимый peak	NC_007113.7:33276014-33276551
signalValue (fold)	21.70
-log10(p) / -log10(q)	109.26 / 100.05
q-value	8.9e-101

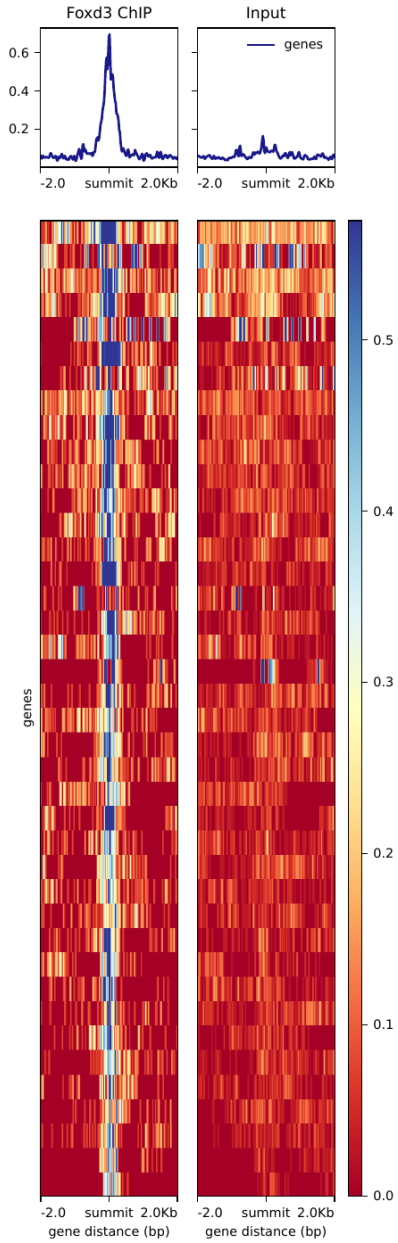
Average profile вокруг summit (слева ChIP, справа Input; шкалы по оси Y у стадий разные):



Peaks очень мало (36), FRiP 0.017%: большая часть ChIP-фрагментов не лежит в вызванных peaks. При этом сильнейший peak обогащён так же, как у других стадий (fold ≈ 21.7). Он расположен в локусе NC_007113.7:33.276 Mb, который виден на всех четырёх стадиях (IGV, локус 2).

На heatmap Input тоже даёт заметный пик в центре (по графику примерно 0.75 против 1.4 у ChIP): часть peaks лежит в участках с повышенным фоновым покрытием, и такое обогащение менее убедительно.

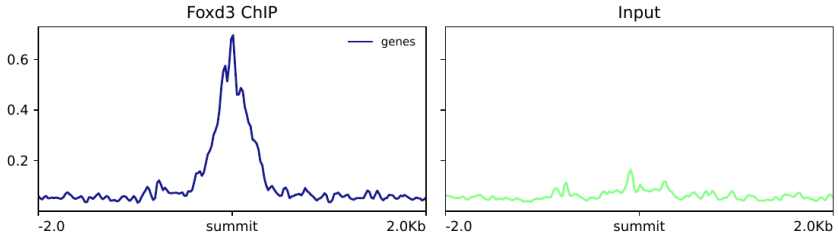
6. QC и peak calling для 1–2 ss



Heatmap ChIP и Input по summits (peaks отсортированы по ChIP-сигналу).

Показатель	Значение
ChIP / Input alignments	12 816 614 / 33 460 348
Peaks (q < 0.01)	40 (из них на scaffolds NW_: 1)
Reads in peaks / FRiP	1 799 / 0.00014
Самый значимый peak	NC_007113.7:33276062-33276596
signalValue (fold)	21.23
-log10(p) / -log10(q)	65.27 / 56.18
q-value	6.6e-57

Average profile вокруг summit (слева ChIP, справа Input; шкалы по оси Y у стадий разные):



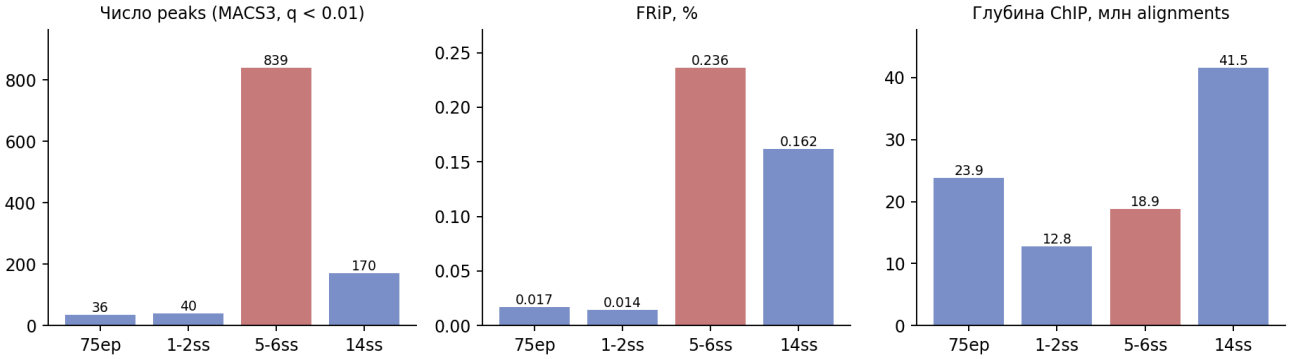
Peaks 40, FRiP 0.014% - самое низкое значение из четырёх стадий. Глубина ChIP здесь меньше всего (12.8 млн alignments), поэтому чувствительность обнаружения слабых peaks ниже, чем на других стадиях.

Профиль чистый: ChIP около 0.69 в центре, Input почти плоский (примерно 0.17). Самый сильный peak лежит в том же месте, что и на 75ep (33.276 Mb, хромосома NC_007113.7).

7. Сводное сравнение четырёх стадий

Stage	ChIP alignments	Input alignments	Peaks	FRiP	max -log10(q)	signalValue топ-peak
75ep	23 863 894	39 931 858	36	0.00017	100.05	21.70
1-2ss	12 816 614	33 460 348	40	0.00014	56.18	21.23
5-6ss*	18 853 396	н/д (BAM не предоставлен)	839	0.00236	163.70	21.10
14ss	41 553 880	27 794 668	170	0.00162	321.45	25.00

* Результаты 5–6 ss получены преподавателем (peaks - teacher/5-6ss, FRiP - frip.tsv: 44 485 / 18 853 396). Самый значимый peak 5–6 ss: NC_007117.7:32206483-32207024, -log10(p) 172.91.

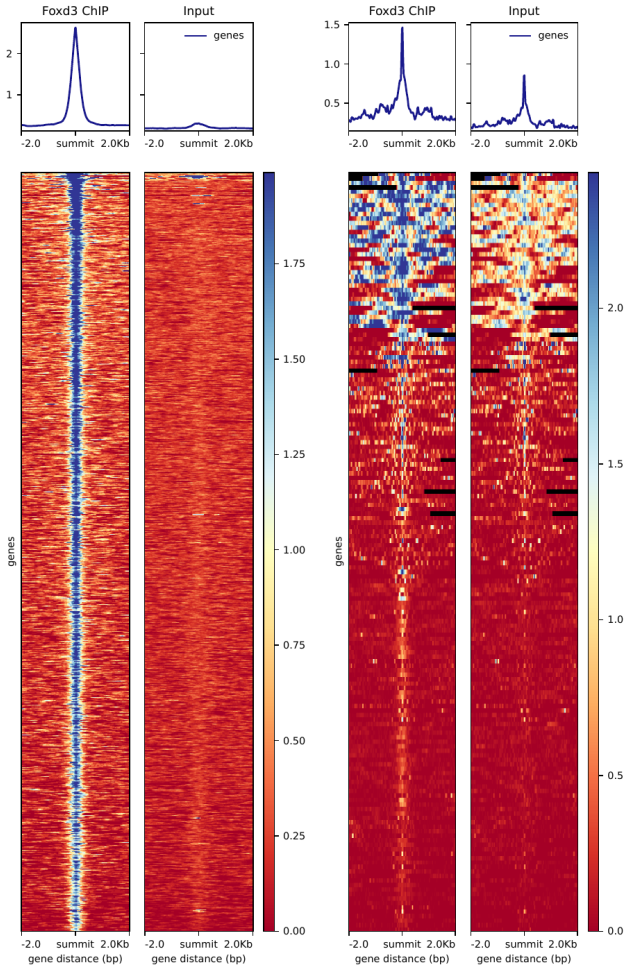


Доля peaks на неприписанных scaffolds (NW_): 75ep 2/36, 1-2ss 1/40, 5-6ss 15/839 (1.8%), **14ss 52/170 (31%)**. Такие contigs часто содержат повторы и плохо картируемые участки, поэтому значительная часть peaks 14 ss, вероятно, технического происхождения.

Ответы на вопросы Части 2

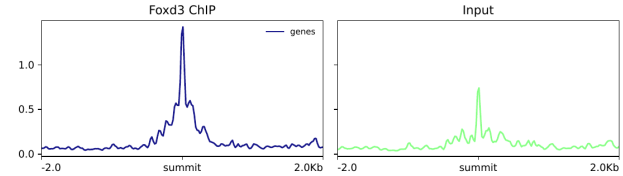
- **Больше всего peaks на 5–6 ss** (839; на 14 ss 170, на 75ep и 1–2 ss около 40). 5–6 ss имеет и самый высокий FRiP (0.24%) и самый чистый профиль.
- **Наиболее выраженный ChIP enrichment** - тоже 5–6 ss: средний профиль достигает ≈2.6 при фоне Input ≈0.3 (см. рисунок ниже). У 14 ss наименьший q-value (-log10 q = 321), но это следствие глубины: ChIP 41.6 млн alignments, в 1.5-3 раза больше, чем у других стадий, а p-value растёт с числом прочтений. По fold-enrichment самых сильных peaks стадии почти не различаются (21.1-25.0).
- **Объяснять разницу числа peaks только биологией нельзя.** Число peaks зависит от глубины и качества библиотек, эффективности иммунопреципитации и доли Foxd3-положительных клеток в образце, качества Input, уровня фона, порога q и параметров peak caller. Например, на 1–2 ss ChIP вдвое мельче, чем на 14 ss, а у 14 ss при самой большой глубине peaks в 5 раз меньше, чем на 5–6 ss: значит, одна глубина разницу не объясняет, а чистоту библиотек мы оценить не можем. Кроме того, 5–6 ss обрабатывалась преподавателем, и идентичность параметров нельзя подтвердить, а реплик нет.

Профили и heatmap четырёх стадий для сравнения (шкалы у стадий разные):

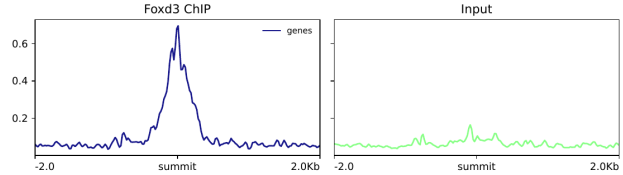


Heatmap слева 5–6 ss (839 peaks), справа 14 ss (170 peaks); в каждой паре слева ChIP, справа Input.

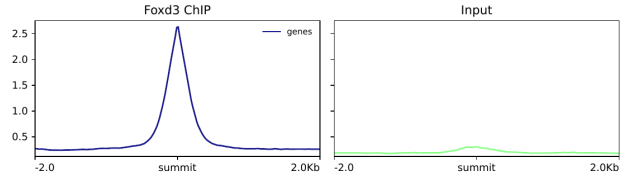
75ep



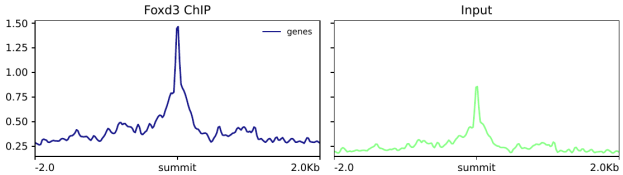
1-2ss



5-6ss



14ss



8. Сравнение genomic intervals между стадиями

A	B	Peaks A	Peaks B	A ∩ B (A пересекается с B)	A-specific (A без B)	% A в B	Jaccard
75ep	1-2ss	36	40	12	24	33%	0.174
75ep	5-6ss	36	839	22	14	61%	0.023
75ep	14ss	36	170	18	18	50%	0.075
1-2ss	5-6ss	40	839	30	10	75%	0.028
1-2ss	14ss	40	170	12	28	30%	0.043
5-6ss	14ss	839	170	40	799	5%	0.037

Jaccard посчитан bedtools jaccard по нуклеотидам, пересечения - bedtools intersect -u и -v. Во всех четырёх стадиях одновременно пересекаются **6 peaks**: NC_007113.7:33276014-33276551, NC_007115.7:24985705-24986018, NC_007117.7:32206595-32206920, NC_007127.7:7514954-7515335, NC_007129.7:44276024-44276290, NC_007131.7:9427912-9428181.

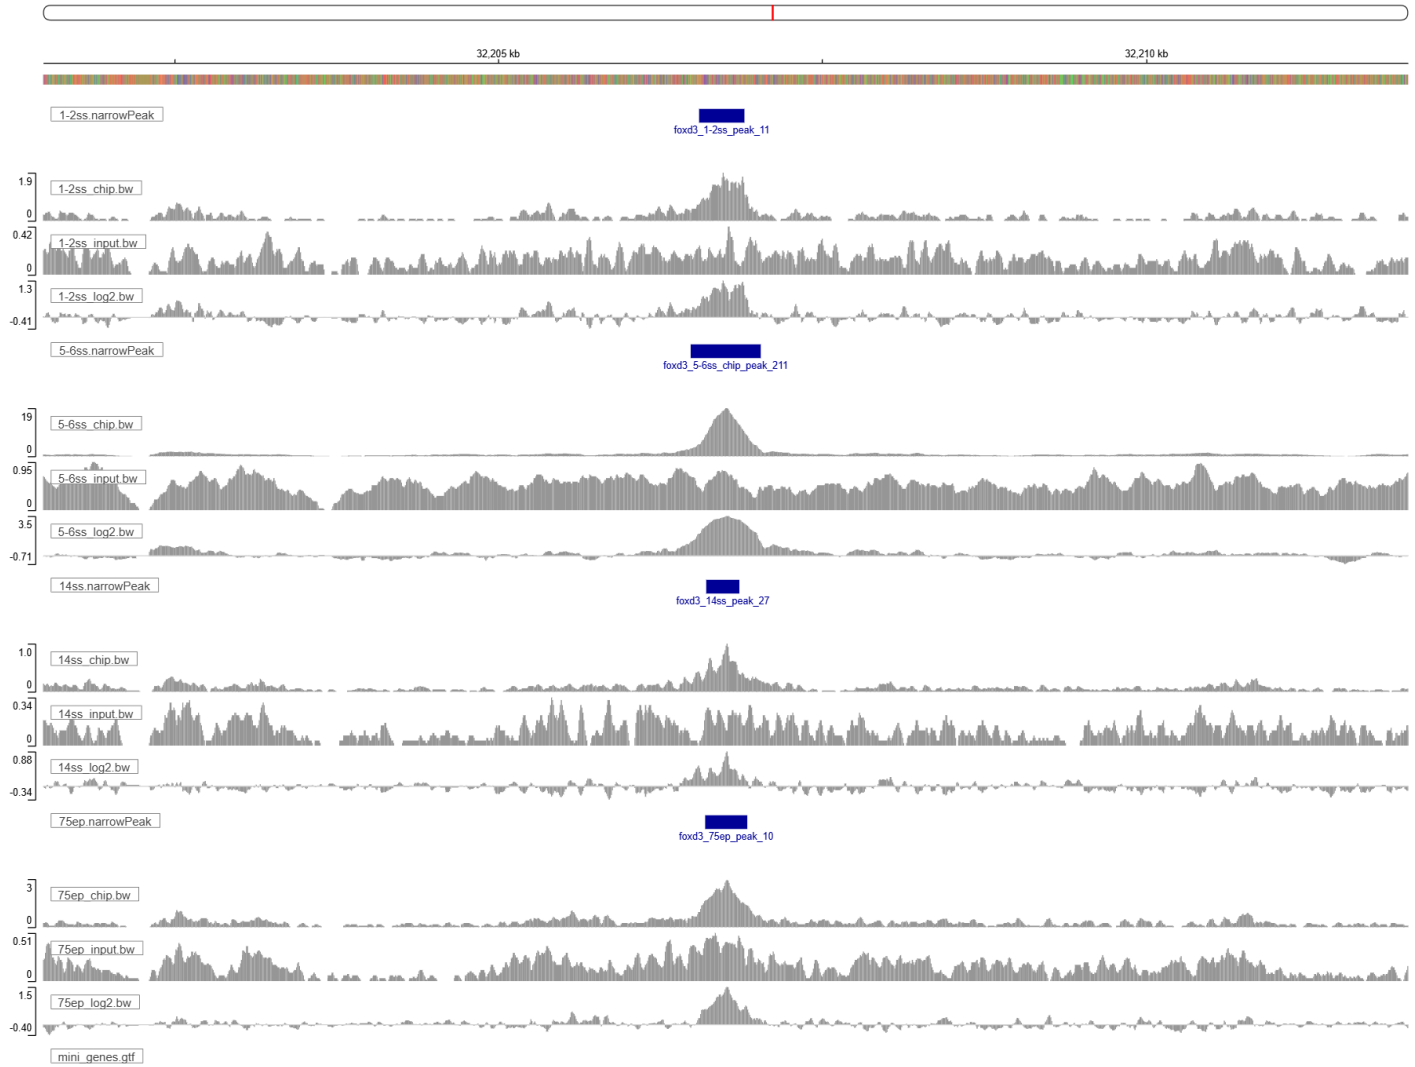
Ответы на вопросы Части 3

- **Наиболее похожи:** 75ep и 1–2ss (Jaccard 0.174, 12 общих peaks из 36 и 40). Но наборы маленькие, а Jaccard зависит от размеров множеств: когда один набор в 20 раз больше (839 peaks), Jaccard низкий автоматически. Поэтому полезнее доля peaks малого набора, которая нашлась в большом: 30 из 40 peaks 1–2ss (75%) и 22 из 36 peaks 75ep (61%) пересекаются с 5–6ss.
- **Наиболее различаются** пары с 5–6ss и 14ss: 5–6ss и 14ss делят только 40 peaks (5% от 839 и 24% от 170), Jaccard 0.037; самое низкое значение 0.023 у пары 75ep и 5–6ss, но оно объясняется в основном разницей размеров.
- **Признаки перестройки есть, но их интерпретация ограничена.** Ранние стадии (36-40 peaks) в основном входят в более богатый набор 5–6ss, то есть выглядят как подмножество, а между 5–6ss и 14ss большая часть peaks (799 из 839) не перекрывается. Однако у 14ss 130 из 170 peaks не совпадают с 5–6ss, и около трети peaks лежат на scaffolds NW_, то есть могут быть артефактами.
- **Отсутствие peak ≠ отсутствие связывания.** peak вызывается только при превышении порога $q < 0.01$, который зависит от глубины, фона и доли клеток с белком. На локусе 3 (IGV) в месте peak 5–6ss на 1–2ss и 14ss виден слабый ChIP-сигнал, не прошедший порог. Кроме того, у стадий разные библиотеки без реплик, поэтому «нет peak» чаще означает «мало данных, чтобы утверждать», а не «связывания нет».

9. IGV

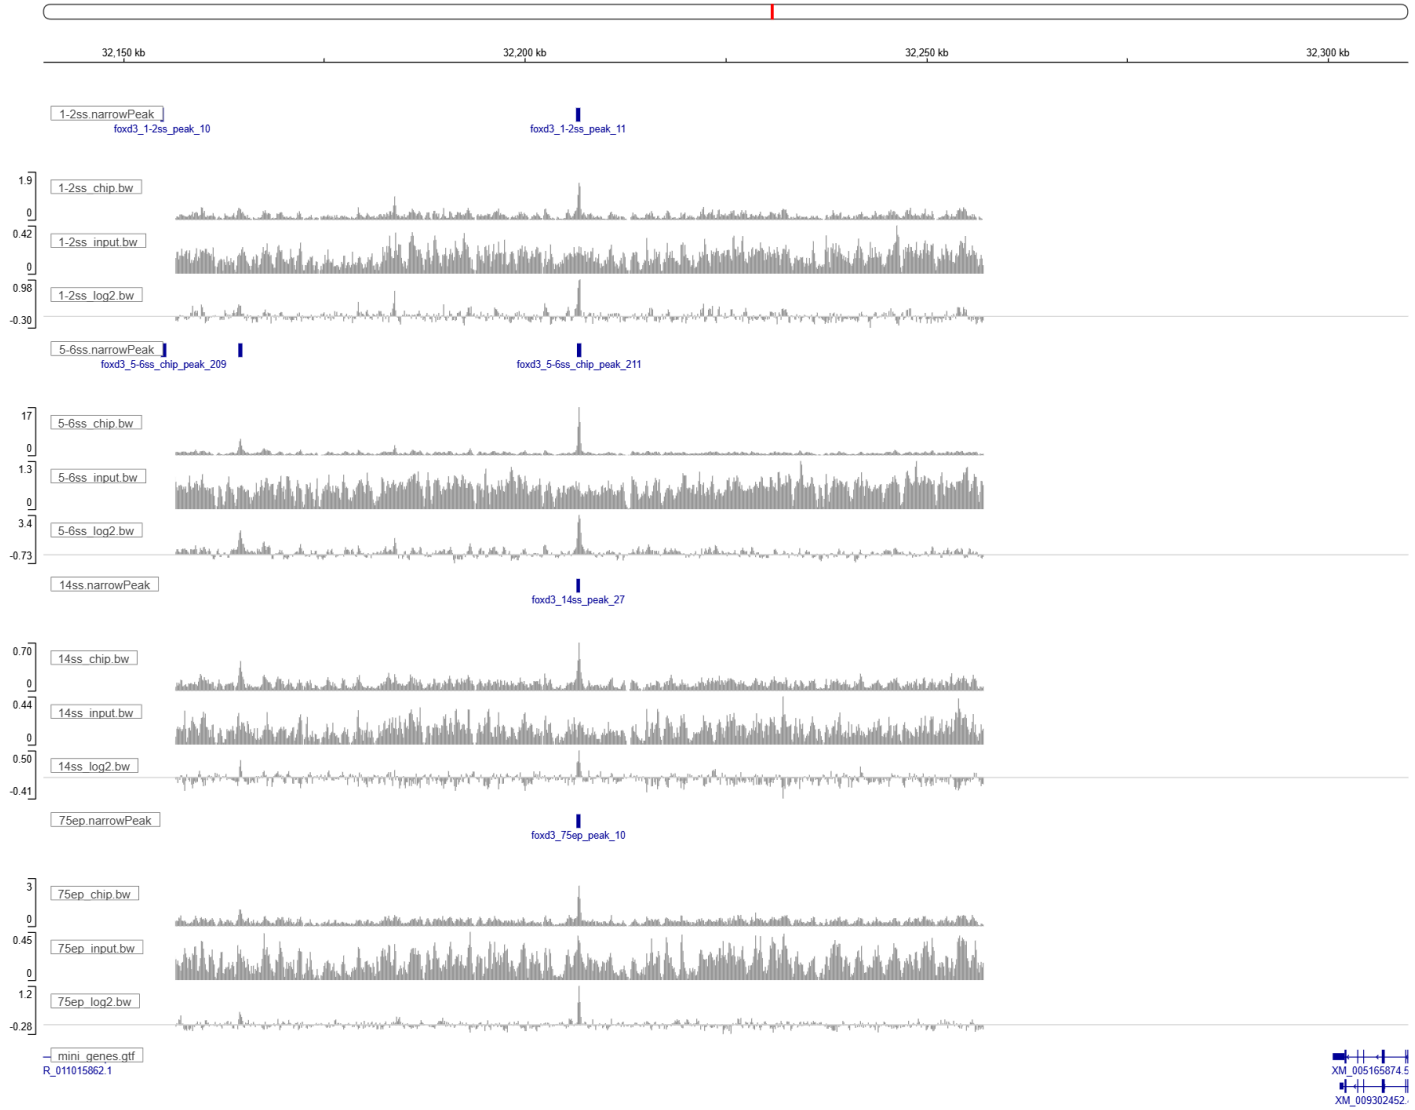
Скриншот 1a. Сильный peak 5–6 ss: NC_007117.7:32,201,483-32,212,024 (±5 kb)

Сверху вниз по стадиям: narrowPeak, ChIP CPM, Input CPM, log2(ChIP/Input) (75ep, 1–2ss, 5–6ss, 14ss; на скриншоте порядок 1-2ss, 5-6ss, 14ss, 75ep), внизу аннотация. Peak 5–6 ss (foxd3_5-6ss_chip_peak_211, самый значимый на этой стадии: signalValue 21.10, -log10 q = 163.70) виден на всех четырёх стадиях в одном месте: 75ep_peak_10, 1-2ss_peak_11, 14ss_peak_27. Input в центре пика не повторяет. В окне нет ни одного гена: peak межгенный. Шкалы автоматические, поэтому сравнивается положение и форма пика.



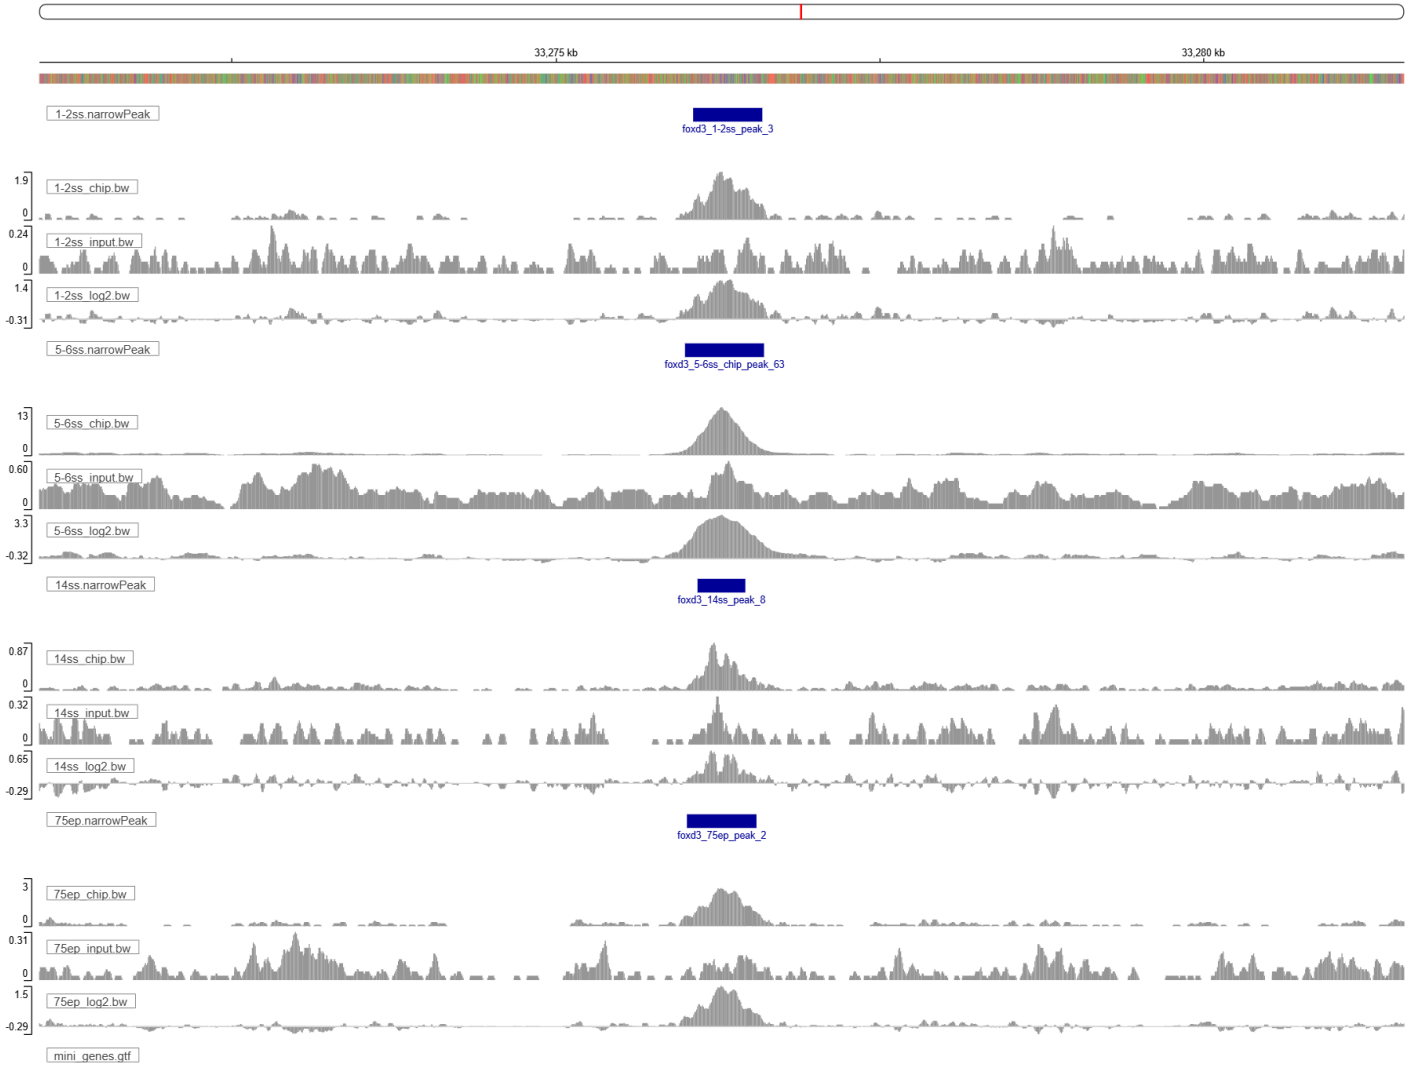
Скриншот 1b. Тот же peak в широком окне: NC_007117.7:32,140,000-32,310,000

Сигнальные файлы вырезаны в окне ±50 kb, поэтому по краям треки пустые. По genes.bed ближайшие гены - LOC137495883 (около 59 kb слева), atg4c (около 94 kb справа), сам foxd3 лежит в 113 kb левее. Это дистальный участок: близость к гену не доказывает, что он регулирует именно его (peak ≠ target gene).



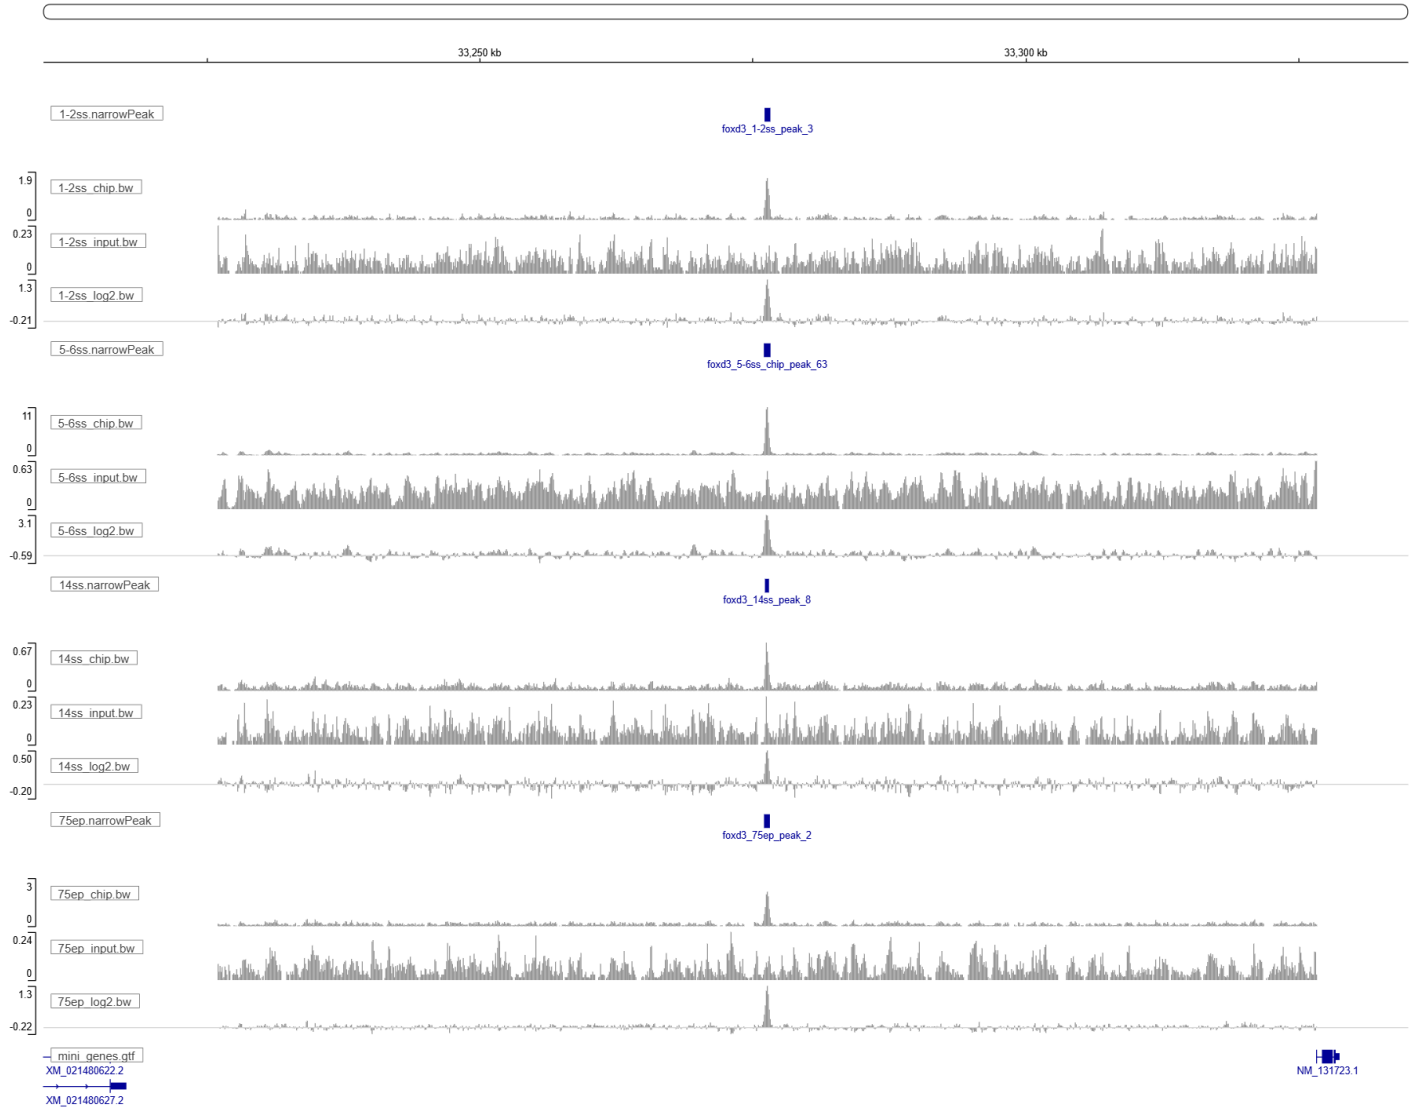
Скриншот 2a. Peak на всех четырёх стадиях: NC_007113.7:33,271,014-33,281,551 (±5 kb)

Peak вызван на каждой стадии: 75ep_peak_2, 1-2ss_peak_3, 5-6ss_chip_peak_63, 14ss_peak_8. Положение и форма совпадают. Это самый сильный peak 75ep (signalValue 21.70, -log10 q = 100.05) и 1–2ss (21.23; 56.18). Enrichment выглядит одинаково по форме, а по высоте различия нельзя интерпретировать из-за разных автоматических шкал: для оценки силы надо опираться на числа MACS3.



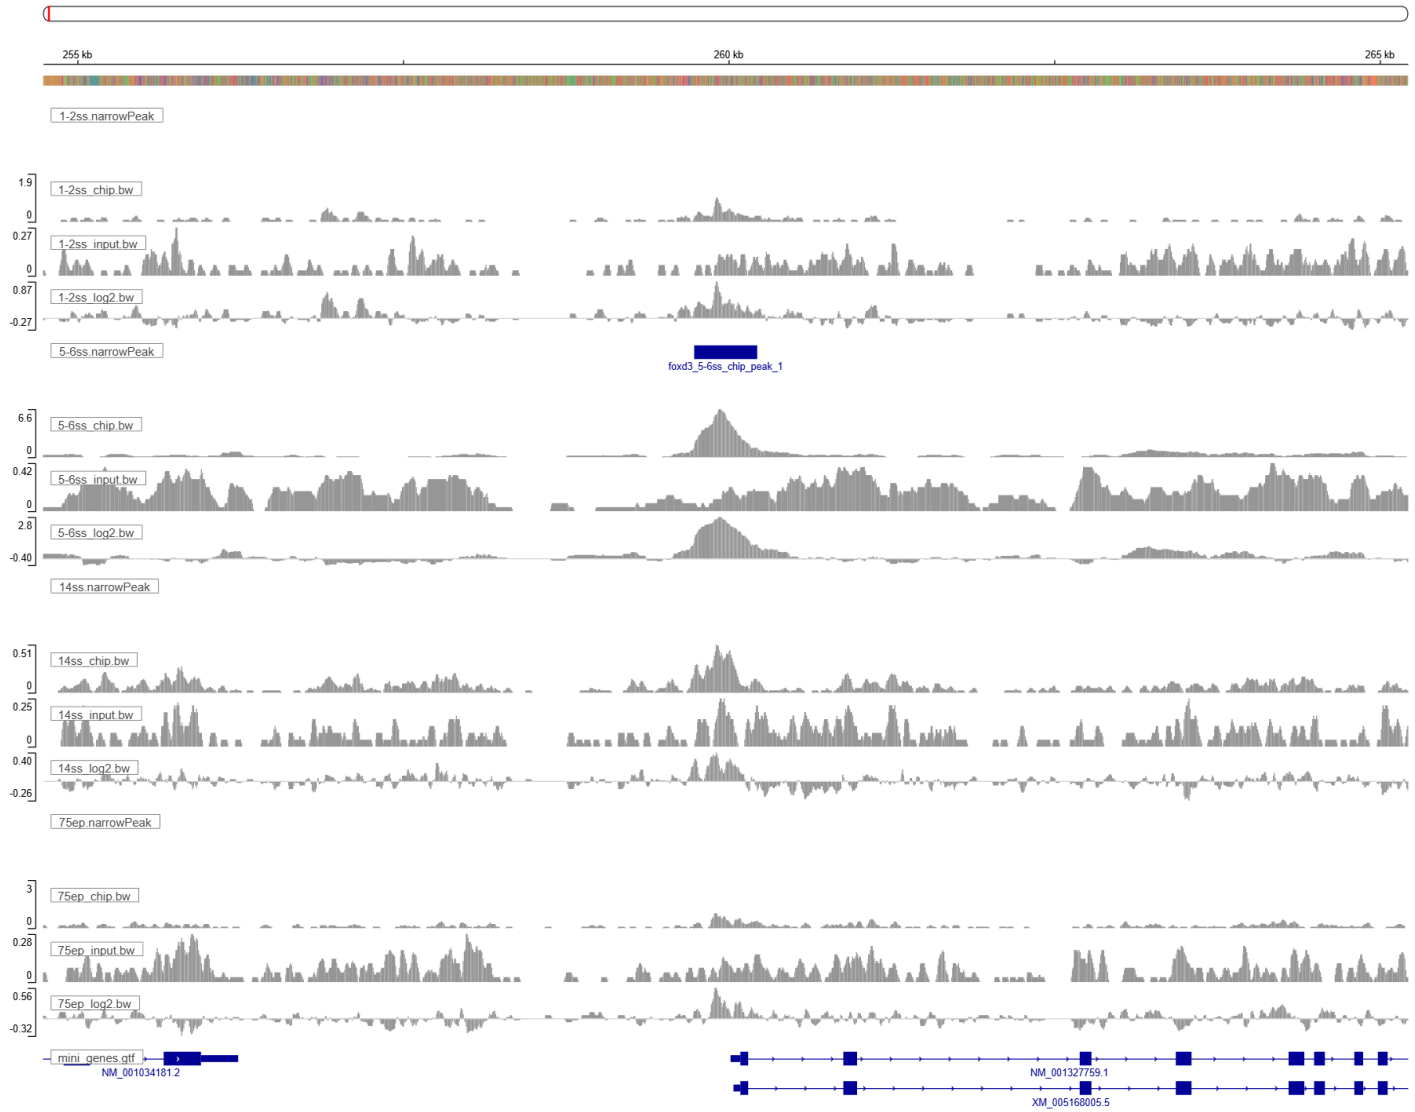
Скриншот 2b. Тот же локус, широкое окно: NC_007113.7:33,210,000-33,335,000

На фоне ровного сигнала это единственный острый пик в окне. Peak находится в межгенном промежутке между rnf220a (слева, примерно 58 kb) и klf17 (справа, примерно 50 kb).



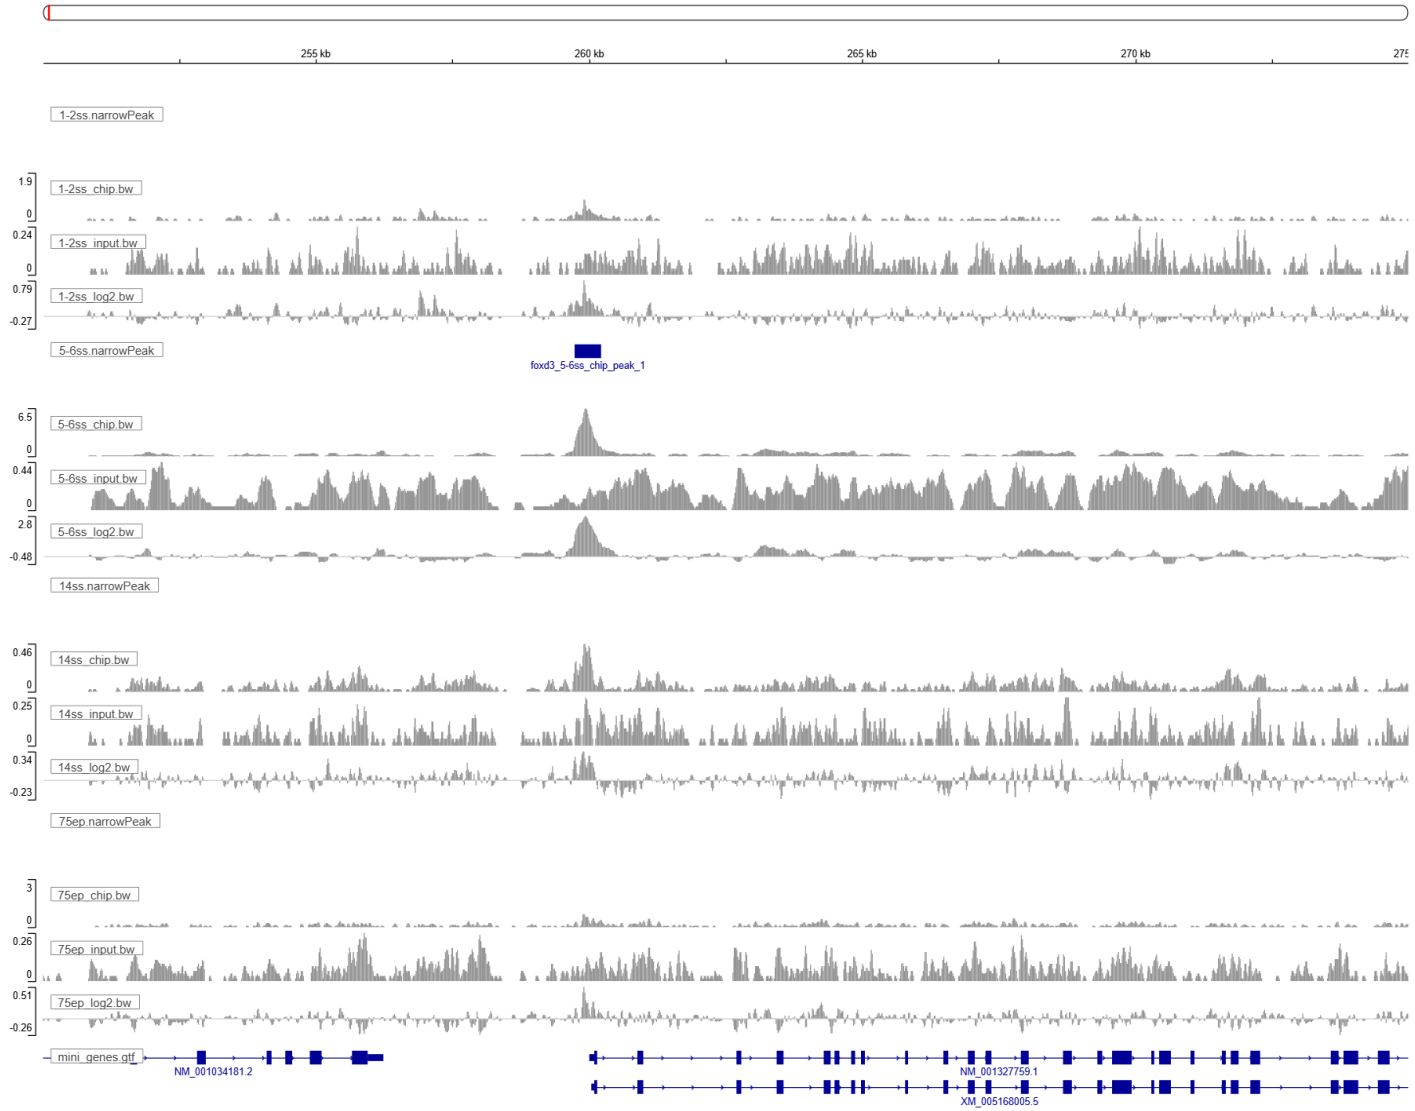
Скриншот 3a. Stage-biased peak 5–6 ss: NC_007112.7:254,734-265,218 (±5 kb)

Peak вызван только на 5–6 ss (foxd3_5-6ss_chip_peak_1: signalValue 20.98, -log10 q = 63.05). Но на 1–2ss и 14ss на том же месте виден слабый локальный подъём ChIP и log2, а на 75ep он почти не различим. То есть это stage-biased, а не строго stage-specific участок. Peak находится в начале гена, лежащего справа (по genes.bed - cenpe, его старт 260,011), то есть на промоторе.



Скриншот 3b. Тот же локус, широкое окно: NC_007112.7:250,000-275,000

Слева виден конец соседнего гена (grk1a), справа - гены cenpe: peak лежит на старте транскриптов. Связывание на промоторе не показывает ни активации, ни репрессии cenpe без данных ATAC-seq, H3K27ac и RNA-seq.



10. Биологическая интерпретация

- **1. Постоянен ли landscape?** Нет. На всех четырёх стадиях есть небольшое стабильное ядро (6 общих peaks), но число peaks и их набор сильно различаются: 36-40 на ранних стадиях, 839 на 5–6 ss, 170 на 14 ss.
- **2. Где самый выраженный сигнал?** На 5–6 ss: максимум числа peaks, самый высокий FRiP (0.24%) и самый чёткий профиль (ChIP ≈2.6 при Input ≈0.3). У 14 ss выше только статистическая значимость (глубина), а fold-enrichment лучших peaks у всех стадий сопоставим (21-25).
- **3. Стабильные участки:** 6 peaks, общих для всех стадий (в том числе NC_007113.7:33.276 Mb, NC_007117.7:32.206 Mb), и большая часть peaks ранних стадий, которые находятся и на 5–6 ss (22 из 36 и 30 из 40).
- **4. Появляются и исчезают:** около 800 peaks 5–6 ss не вызваны на 14 ss (возможное «исчезновение» связывания к миграции), а на 14 ss есть 130 peaks без перекрытия с 5–6 ss. Однако по локусу 3 видно, что часть «исчезающих» peaks остаётся в виде слабого сигнала ниже порога, а 31% peaks 14 ss лежат на scaffolds NW_.
- **5. Почему ChIP-seq не говорит об активации или репрессии:** ChIP-seq показывает только, где белок связан. Binding ≠ regulation: peak не говорит, активирует или подавляет белок транскрипцию. Peak ≠ target gene: самый сильный peak 5–6 ss лежит в 113 kb от foxd3 и в десятках kb от ближайших генов. ChIP-seq не показывает, открыт ли хроматин, активен ли enhancer и меняется ли экспрессия.
- **6. Что нужно из статьи:** ATAC-seq (доступность хроматина в control и foxd3 mutant, нужно ли Foxd3 для открытия региона), H3K27ac ChIP-seq (активность enhancer-ов в этих регионах) и RNA-seq (bulk и single-cell: меняется ли экспрессия генов в foxd3 mutant). Если peak Foxd3 совпадает с регионом, чья доступность или H3K27ac меняется в mutant, а соседний ген меняет экспрессию, связывание можно считать функциональным. Эти данные проверили бы и модель статьи о переходе Foxd3 из pioneer-фактора в репрессор.

11. Вывод

Foxd3 связывается с небольшим стабильным набором участков на всех четырёх стадиях (6 общих peaks), а число и набор остальных peaks меняются: 36 на 75ep, 40 на 1–2ss, 839 на 5–6ss и 170 на 14ss. Наиболее выраженное и чистое связывание наблюдается на 5–6 ss. Большая часть peaks ранних стадий воспроизводится на 5–6ss, то есть набор участков в ходе спецификации расширяется, а затем на 14 ss сокращается и частично заменяется другими.

Итоговый вопрос. Что можно считать биологическим: существование небольшого стабильного ядра сайтов; то, что сильные peaks видны на нескольких стадиях в одних и тех же местах; то, что на 5–6ss связывание самое выраженное по профилю ChIP/Input. Что отделить от качества ChIP-seq нельзя: абсолютные числа peaks, вывод «peak исчез» (локус 3 показывает слабый сигнал ниже порога), сравнение значимости (-log10 q зависит от глубины: у 14ss она максимальна), состав peaks 14ss (31% на NW_ scaffolds, заметный сигнал Input на summits) и сравнение с 5–6ss, обработанной преподавателем без доступных BAM Input. Из-за отсутствия реплик и разных эффективностей иммунопреципитации различия в числе peaks остаются предварительными: для биологического вывода нужны реплики, один и тот же пайплайн для всех стадий и ATAC-seq, H3K27ac и RNA-seq.